Lab 6: Deep Q-Network and Deep Deterministic Policy Gradient

311581005 智能碩一 吳佳豪

1 A TENSORBOARD PLOT SHOWS EPISODE REWARDS OF AT LEAST 800 TRAINING EPISODES IN LUNARLANDER-V2

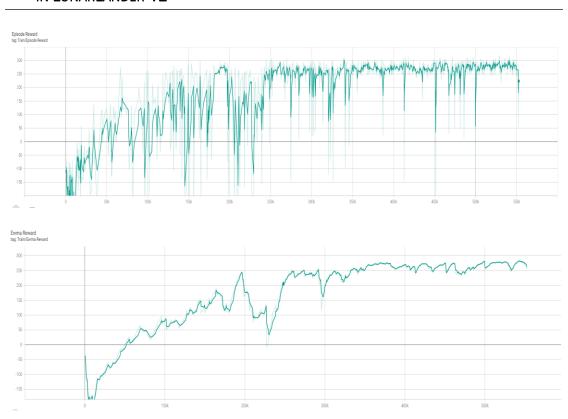


Figure 1. Rewards with DQN

2 A TENSORBOARD PLOT SHOWS EPISODE REWARDS OF AT LEAST 800 TRAINING EPISODES IN LUNARLANDERCONTINUOUS-V2

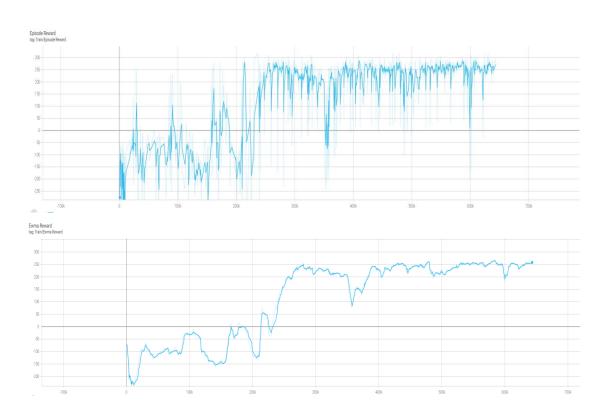


Figure 2. Rewards with DDPG

3 DESCRIBE YOUR MAJOR IMPLEMENTATION OF BOTH ALGORITHMS IN DETAIL.

3.1 DQN

首先下面的程式碼主要建構一個 NN 的 Model 來做到輸入 State 時預測下個 action,因為環境為 LunarLander-v2,所以建構輸入為 State dim=8 而輸出為 action dim=4 的模型,並為了可以方便測試不同 hidden layers,所以建構方式可以自行設定層數與數量大小,經過測試後發現中間 hidden 的層數使用(400,200)的大小就可以得到不錯的成效,因此將此數值設定為預設大小。

Figure 3. Implement action model

下方程式碼實現演算法中的 epsilon-greedy 主要控制 DQN 要選擇哪個 action,如果 random 的數值小於 epsilon 就隨機選擇一種方法,反之則從所有 action 中找到可以獲取 到最大的 Q value 的 action。這樣的方法可以增加探索能力,避免只會重複走相同的 action。

With probability ε select a random action a_t otherwise select $a_t = \operatorname{argmax}_a Q(\phi(s_t), a; \theta)$

Figure 4. Epsilon-greedy algorithm

```
def select_action(self, state, epsilon, action_space):
    '''epsilon-greedy based on behavior network'''
    ## TODO ##
    if random.random() < epsilon:
        return action_space.sample()
    else:
        with torch.no_grad():
        return self._behavior_net(torch.from_numpy(state).view(1,-1).to(self.device)).max(dim=1)[1].item()</pre>
```

Figure 5. Implement the method of using epsilon-greedy in DQN

下方程式碼實現如 Figure 6.中的演算法,先隨機從 buffer 中 sample 一個 batch 大小的資料,接著將 state 資料傳給 behavior_network 中來得到選擇特定 action 的 Q value,之後將 next state 輸入到 target_network 中來得到最大的 Q value 並使用 bellman Equation 計算 Q target 值,得到了 Q value 與 Q target 就可以計算 loss 且更新 behavior_network 模型參數,然後經過 c 個 step 後再更新 target network 的參數,並重複下去進行訓練。

Sample random minibatch of transitions $\left(\phi_{j},a_{j},r_{j},\phi_{j+1}\right)$ from D $\text{Set } y_{j} = \begin{cases} r_{j} & \text{if episode terminates at step } j+1 \\ r_{j}+\gamma \max_{a'} \hat{Q}\left(\phi_{j+1},a';\theta^{-}\right) & \text{otherwise} \end{cases}$ $\text{Perform a gradient descent step on } \left(y_{j}-Q\left(\phi_{j},a_{j};\theta\right)\right)^{2} \text{ with respect to the network parameters } \theta$ $\text{Every } C \text{ steps reset } \hat{Q} = Q$

Figure 6. Some train part in DQN algorithm

```
def update(self, total_steps):
    if total_steps % self.freq == 0:
        self._update_behavior_network(self.gamma)
    if total_steps % self.target_freq == 0:
        self._update_target_network()
def _update_behavior_network(self, gamma):
    state, action, reward, next_state, done = self._memory.sample(
        self.batch_size, self.device)
    ## TODO ##
    q_value = self._behavior_net(state).gather(dim=1,index=action.long())
    with torch.no_grad():
       q_next = self._target_net(next_state).max(dim=1)[0].view(-1,1)
        q_target = reward + (gamma * q_next * (1 - done))
    loss = nn.MSELoss()(q_value, q_target)
    self._optimizer.zero_grad()
    loss.backward()
    nn.utils.clip_grad_norm_(self._behavior_net.parameters(), 5)
    self. optimizer.step()
def _update_target_network(self):
    '''update target network by copying from behavior network'''
    self._target_net.load_state_dict(self._behavior_net.state_dict())
```

Figure 7. Implement train part in DQN algorithm

3.2 DDPG

DDPG 是由 actor 和 critic 兩個 network 組合而成的架構,下方為實作兩個 model 的程式碼,經過測試後發現 hidden layers 使用(400,200)有不錯的效果,所以將數值設為 hidden layers 的預設大小。

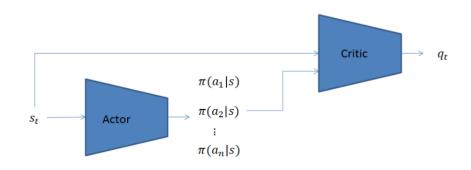


Figure 8. DDPG architecture

Figure 9. Implement Actor and Critic network

下方程式碼主要實作 DDPG 在回傳 action 時,會選擇 actor_net 傳回的 action 並加入雜訊在其中,來增加探索的能力。

Select action $a_t = \mu(s_t | \theta^{\mu}) + N_t$ according to the current policy and exploration noise

Figure 10. The method of selecting the action in DDPG

```
def select_action(self, state, noise=True):
    '''based on the behavior (actor) network and exploration noise'''
    ## TODO ##
    with torch.no_grad():
        re = self._actor_net(torch.from_numpy(state).view(1,-1).to(self.device))
        if noise:
            re = re + torch.from_numpy(self._action_noise.sample()).view(1,-1).to(self.device)
        return re.cpu().numpy().squeeze()
```

Figure 11. Implement the method of selecting the action in DDPG

下方程式碼實作如 Figure 12.演算法,主要與 DQN 訓練方式差不多,差在會將 actor 的輸出接到 critic 的輸入,並且使用 target_actor 來拿到下個 action 的值後傳入 target_critic 後得到 Q value 並使用 bellman Equation 計算 Q target 值,得到了 Q value 與 Q target 可以計算 loss 並更新 critic 網路,再來會將 state 傳入 actor 中取得當前的 action,並將當前 action 傳到 critic 中得到輸出平均後取負值當成 loss 並更新 actor 網路。

Sample random minibatch of N transitions (s_j, a_j, r_j, s_{j+1}) from RSet $y_i = r_i + \gamma Q'(s_{t+1}, \mu'(s_{t+1}|\theta^{\mu'})|\theta^{Q'})$

Update critic by minimizing the loss: $L = \frac{1}{N} \sum_{i} (y_i - Q(s_i, a_i | \theta^Q))^2$

Update the actor policy using the sampled gradient:

$$\nabla_{\theta^{\mu}\mu}|s_{i} \approx \frac{1}{N} \sum_{i} \nabla_{a}Q(s, a|\theta^{Q})|_{s=s_{i}, a=\mu(s_{i})} \nabla_{\theta^{\mu}\mu}(s|\theta^{\mu})|s_{i}$$

Update the target networks:

$$\theta^{Q'} \leftarrow \tau \theta^{Q} + (1 - \tau)\theta^{Q'}$$
$$\theta^{\mu'} \leftarrow \tau \theta^{Q} + (1 - \tau)\theta^{\mu'}$$

Figure 12. Some train part in DDPG algorithm

Figure 13. Implement some train part in DDPG algorithm

4 DESCRIBE DIFFERENCES BETWEEN YOUR IMPLEMENTATION AND ALGORITHMS.

多一個 warmup 的機制,在剛開始訓練時會隨機的選擇 action 來增加 replay buffer 的資料,並且在遊玩的過程中不會更新模型參數,來達到隨機探索的功效,豐富資料的多樣性。

5 Describe your implementation and the gradient of actor updating.

會將 state 傳入 actor 中取得當前的 action,並將當前 action 傳到 critic 中得到輸出平均後取負值當成 loss 並更新 actor 網路(實作可參考標題 3.2)。

Update the actor policy using the sampled gradient:

$$\nabla_{\theta^{\mu}\mu}|s_{i} \approx \frac{1}{N} \sum_{i} \nabla_{a}Q(s, a|\theta^{Q})|_{s=s_{i}, a=\mu(s_{i})} \nabla_{\theta^{\mu}\mu}(s|\theta^{\mu})|s_{i}$$

Figure 14. The algorithm of the gradient of actor updating

使用 target_actor 來拿到下個 action 的值後傳入 target_critic 後得到 Q value 並使用 bellman Equation 計算 Q target 值,得到了 Q value 與 Q target 就可以計算 loss 並更新 critic 網路(實作可參考標題 3.2)。

Set
$$y_i = r_i + \gamma Q'(s_{t+1}, \mu'(s_{t+1}|\theta^{\mu'})|\theta^{Q'})$$

Update critic by minimizing the loss: $L = \frac{1}{N} \sum_i (y_i - Q(s_i, a_i|\theta^Q))^2$

Figure 15. The algorithm of the gradient of critic updating

7 EXPLAIN EFFECTS OF THE DISCOUNT FACTOR.

隨著時間越久對給予的 reward 影響應該要越來越少,代表越剛發生的 reward 應該 reward 要影響最大,所以下個值通常會乘上一個介於 0<gamma<1 的值,來達到逐漸遞減。

8 EXPLAIN BENEFITS OF EPSILON-GREEDY IN COMPARISON TO GREEDY ACTION SELECTION

如果只使用 greedy 的方法,在一開始訓練時找到一條較高的 reward 時,就會使網路每次遇到相同狀況都選擇相同 action,而不探索新的 action,會限制網路。而使用 epsilon-greedy 時,因為會隨機的選擇不同的 action,所以可以解決想是遇到剛好此次 action 較差但卻是最佳解路徑的情況,使網路有探索(exploration)的能力。

9 EXPLAIN THE NECESSITY OF THE TARGET NETWORK

得知 $Q\pi(st,at)=rt+Q\pi(st+1,\pi(st+1))$,而 $Q\pi(st,at)$ 為輸出,目標為 $rt+Q\pi(st+1,\pi(st+1))$ 是會變動的,所以如果都使用相同的 network 時,因為模型參數會一直更新,因此會使訓練極為不穩定,為了改善此問題而有了 target network,將 target network 的 $Q\pi$ 固定住後即 $rt+Q\pi(st+1,\pi(st+1))$ 變成固定,那對於 behavior network 就只是解單純的 regression 的問題,等迭代幾次後再將 target network 的 $Q\pi$ ru 更新。

10 EXPLAIN THE EFFECT OF REPLAY BUFFER SIZE IN CASE OF TOO LARGE OR TOO SMALL

如果 buffer 過於大的話,雖然可以使訓練穩定,但是也會使得訓練速度變慢。如果 buffer 過小時,因為只會存有最近的 data 資料,所以會重於最近遊玩的狀態,而導致 overfitting 的狀況出現。

發現因為在 DQN 中會發生高估 Q value 的情況發生,所以修改下方公式,原本是從 target_network 中取得,變成從在 behavior_network 中可以獲得最大 Q value 的 action 後,在將 action 當成 target_network 的參數傳入並經過 Bellman 取得 Q target。

$$\begin{aligned} \mathbf{Y}_{t}^{Q} &= r_{t+1} + \gamma \max_{a} Q(S_{t+1}, \boldsymbol{a} | \boldsymbol{\theta}^{-}) \\ & & \qquad \qquad \boldsymbol{\Psi} \\ \mathbf{Y}_{t}^{DoubleQ} &= r_{t+1} + \gamma Q\left(S_{t+1}, \underbrace{\underset{a}{\operatorname{argmax}} Q(S_{t+1}, \boldsymbol{a} | \boldsymbol{\theta})}_{\boldsymbol{a}} | \boldsymbol{\theta}^{-}\right) \end{aligned}$$

Figure 16. Between DQN and DDQN different part

Figure 17. Implement update_behavior_network function in DDQN

下方為測試的實驗結果:

```
• Python .\ddqn.py --test_only --seed 1
Start Testing
total reward: 298.27
total reward: 261.48
total reward: 293.68
total reward: 294.55
total reward: 296.20
total reward: 305.21
total reward: 253.42
total reward: 310.99
total reward: 295.05
total reward: 295.46
Average Reward 290.43137977015004
```

Figure 18. The result of DDQN

```
• Testing
total reward: 309.21
total reward: 300.77
total reward: 300.17
total reward: 288.62
total reward: 304.85
total reward: 283.40
total reward: 290.50
total reward: 294.77
Average Reward 293.811974394545
```

Figure 18. The result of DQN

13 [LUNARLANDERCONTINUOUS-V2] AVERAGE REWARD OF 10 TESTING EPISODES:

```
python ddpg.py --test_only --seed 1
Start Testing
total reward: 303.30
total reward: 279.97
total reward: 304.22
total reward: 305.29
total reward: 250.26
total reward: 297.48
total reward: 281.13
total reward: 279.65
total reward: 288.31
total reward: 303.02
Average Reward 289.2637501056921
```

Figure 18. The result of DDPG